Visualisasi Data Menggunakan Python

Diajukan untuk melengkapi tugas matakuliah Big Data dari dosen pengajar Dr. Taufik Fuadi Abidin, S.Si., M.Tech.

Oleh:

BUDI GUNAWAN

1608107010009

JURUSAN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA
DARUSSALAM, BANDA ACEH

DAFTAR ISI

PEMBAHASAN

A. Proses Crawling

Sebelum melakukan visualisasi data, terlebih dahulu kita harus mempersiapkan data berita yang dapat diperoleh dari hasil crawling situs portal berita nasional. Dalam laporan ini, data diambil dari situs detik.com. Total file berjumlah 3001 buah data html. Kode python yang digunakan bernama codeperl.py yang dapat dijalankan dengan

python3 codeperl.py <new_file.txt>

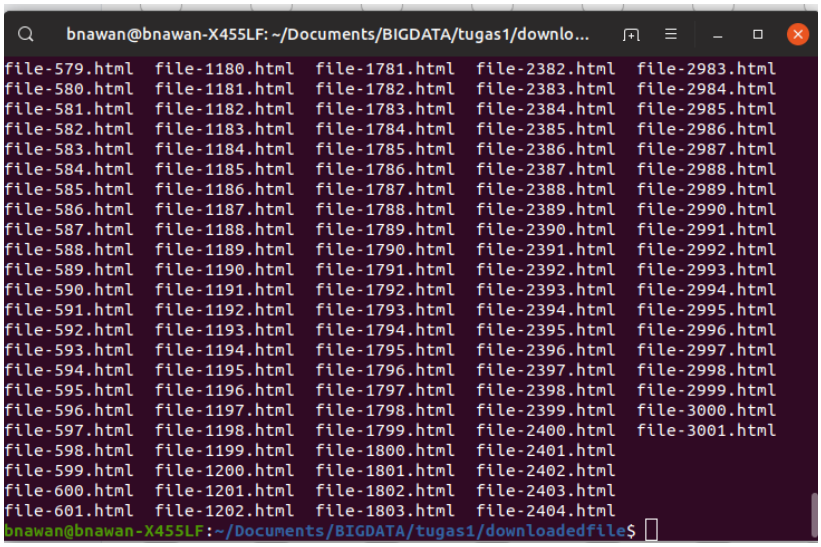

Gambar 1 : Total data

Sebelum melakukan crawling, carilah terlebih dahulu semua link yang ada pada halaman index portal berita. Karena menggunakan python versi 3, maka digunakanlah library *mechanicalsoup* yang secara teknis memiliki banyak kesamaan dengan mechanize yang tidak dapat dijalankan pada python versi 3.

```
65                  halaman+=1
66                  browser.open(url)
67                  test=browser.links()
68                  for link in test:
69                      page=link['href']
70                      a = re.search("/berita/",page)
71                      if (a) and page not in urls:
72                          urls[page]=dateTimeObj
73                          count+=1
74                          print("\rTanggal "+str(tanggal)+" bulan "+str(bulan)+" => Total link(s) : "+str(count))
75                          if count >= 3000:
76                              forcebreak = True
77                              break
78              if forcebreak: break
79              tgl1+=1
80          if forcebreak: break
81          bln1+=1
82      if forcebreak: break
83      thn1+=1
84
85
86  browser.close()
87  for link in urls.keys():
88      f.write(link+"\n")
89
```

Gambar 2 : Penggalan kode crawling

Pada metode mechanicalsoup, terlebih dahulu kita membuat objek yang di sini diberi nama browser. Agar dapat digunakan, kita harus membukanya dengan menjalankan *browser.open(url)*. Setelah itu dapatkan semua link pada halaman tersebut dengan *browser.links()*. Untuk memeriksa satu persatu kode tersebut, maka lakukan foreach untuk setiap link dan karena return dari *browser.links()* masih memiliki atribut html, maka kita dapat mengambil linknya dengan memasukkan key berupa atribut itu sendiri yaitu *link[href]*. Lalu lakukan pengecekan kembali karena berita yang diambil haruslah berita dengan melakukan regex terhadap url yang didapat. Setelah itu, barulah url dapat dimasukkan ke dalam hash yang kemudian akan ditulis ke dalam file txt yang menjadi salah satu input argumen pada konsol untuk menjalankan kode ini.

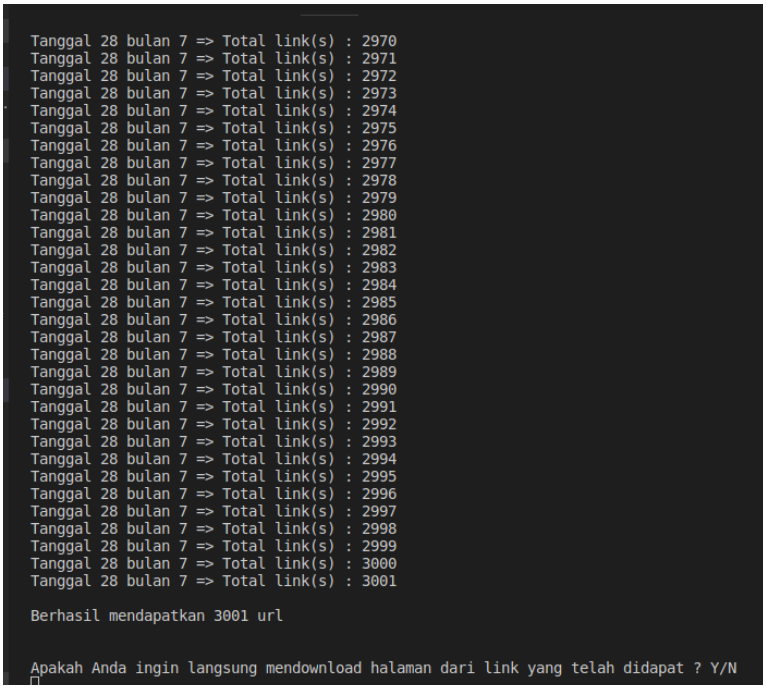

Gambar 3: Penggalan kode crawling

Gambar 4: Penggalan kode crawling

Kemudian, setelah semua link terkumpul dalam semua file, lakukanlah crawling di mana kita akan menggunakan download.py yang akan tertriggered setelah menekan input y. Di sini kita akan melakukan wget untuk mengambil data dari server tersebut.

B. Proses Ekstrak Konten

Jika anda telah mencapai tahap ini, berarti anda telah memperoleh data sebanyak 3001 buah. Pada tahap ini, dilakukan pembersihan terhadap tag-tag html yang tidak diperlukan sehingga hanya menyisakan title, tanggal, dan konten teks. Di sini kita akan menggunakan kode extcontent.py dengan menjalankan perintah *python3 extcontent.py*. Data hasil ekstrak konten akan menghasilkan output berekstensi *bersih.dat*

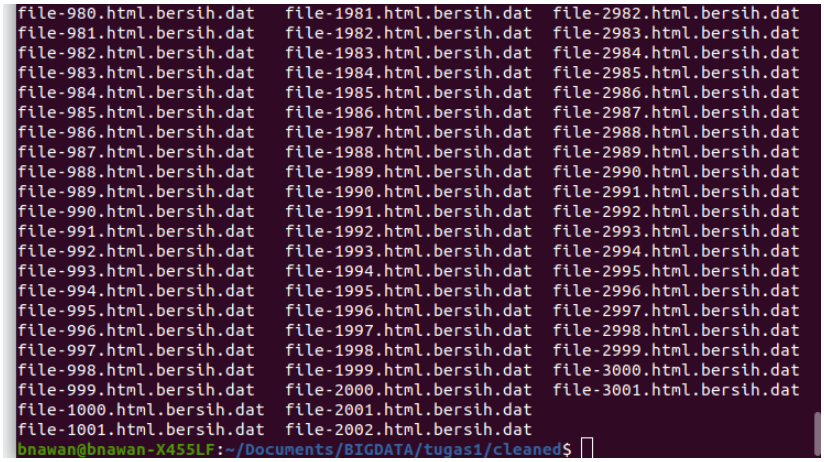

Gambar 5: Output ekstrak konten

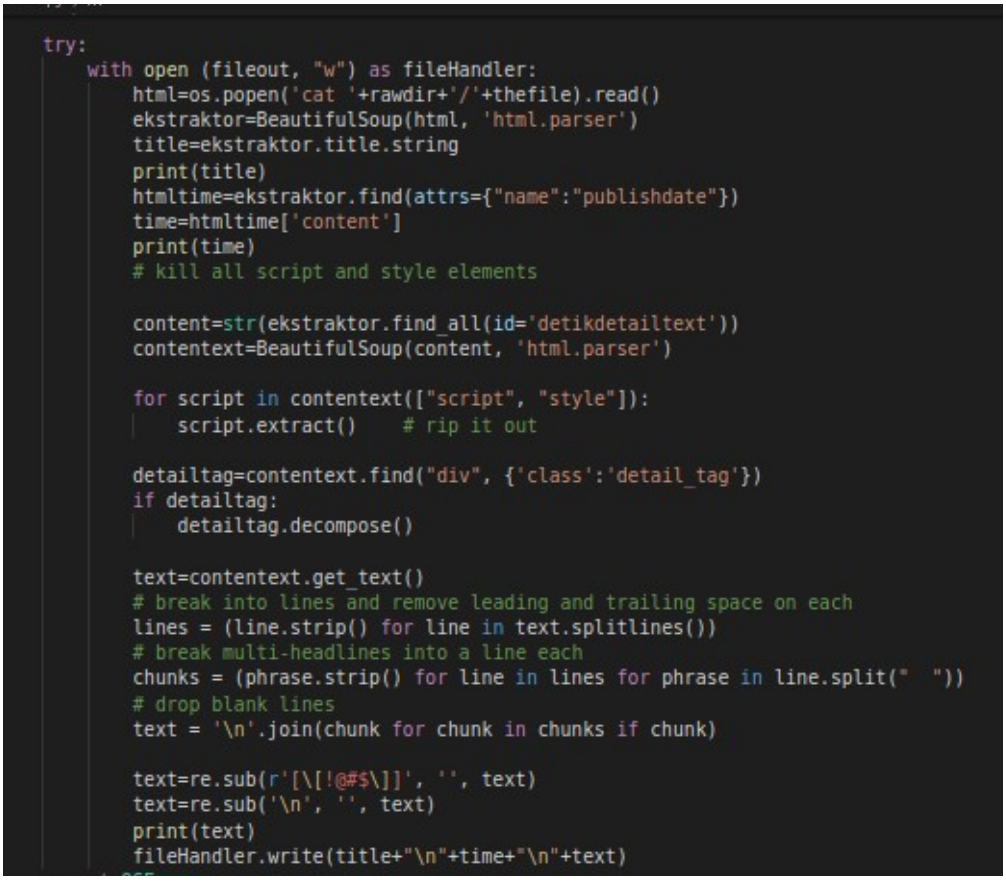

```
try:
    with open (fileout, "w") as fileHandler:
        html=os.popen('cat '+rawdir+'/'+thefile).read()
        ekstraktor=BeautifulSoup(html, 'html.parser')
        title=ekstraktor.title.string
        print(title)
        htmltime=ekstraktor.find(attrs={"name":"publishdate"})
        time=htmltime['content']
        print(time)
        # kill all script and style elements

        content=str(ekstraktor.find_all(id='detikdetailtext'))
        contentext=BeautifulSoup(content, 'html.parser')

        for script in contentext(["script", "style"]):
            script.extract()    # rip it out

        detailtag=contentext.find("div", {'class':'detail_tag'})
        if detailtag:
            detailtag.decompose()

        text=contentext.get_text()
        # break into lines and remove leading and trailing space on each
        lines = (line.strip() for line in text.splitlines())
        # break multi-headlines into a line each
        chunks = (phrase.strip() for line in lines for phrase in line.split("  "))
        # drop blank lines
        text = '\n'.join(chunk for chunk in chunks if chunk)

        text=re.sub(r'[\[!@#$\]]', '', text)
        text=re.sub('\n', '', text)
        print(text)
        fileHandler.write(title+"\n"+time+"\n"+text)
```

Gambar 6 : Penggalan kode ekstrak konten

Di sini kita akan menggunakan library *Beautifulsoup* untuk dapat mengekstrak dan melakukan selection terhadap file html. Seperti sebelumnya, kita akan membuat objek yang diberi nama ekstraktor. Untuk mengambil title, dapat menggunakan fungsi bawaannya dengan memanggil *ekstraktor.title.string* Sedangkan untuk mengambil tanggal, karena pada file html detik.com tanggal berada pada atribut name publishdate, maka lakukan find dengan menggunakn objek ekstraktor dan ambil tanggal tersebut dengan memasukkan key yaitu content pada variabel yang menampung hasil find karena tanggal berada pada atribut content. Terakhir, untuk ekstrak isi beritanya, find all semua teks yang berada pada tag “detikdetailteks” dan gunakan fungsi bawaan get_teks. Di sini kita akan menambah objek baru bernama *contentext* agar lebih mudah dalam menghilangkan atribut ataupun semua yang tidak dibutuhkan dalam teks utama tersebut.

C. Bar Chart Plotting

Untuk melakukan plotting 10 kata terbaik dalam 3000 berita tersebut, kode yang akan digunakan adalah chart10best.py. Pertama-tama, library yang dibutuhkan adalah library NLTK untuk melakukan pemisahan kata demi kata atau biasa dilakukan untuk ngram dan pembuatan kamus. Sebelum melakukan ngramming, pastikan data telah ditokenize dan dibuat lower semua. Kondisinya di sini, kita tidak menghilangkan *stopword*nya. Setelah itu, barulah dilakukan ngramming. Kata-kata yang didapatkan dimasukkan ke dalam hash dan value yang akan terus diupdate sesuai frekuensinya. Kemudian, lakukan sorting secara descending dan ambillah top 10 tertinggi yang akan dimasukkan ke dalam 2 variabel array karena untuk membuat plotting, dibutuhkan data dalam array untuk melakukan plotting. Lalu, barulah kita akan melakukan plotting dengan menjalankan setiap fungsi bawaan yang terdapat dalam library matplolib sehingga akan menghasilkan output berupa bar chart histogram.

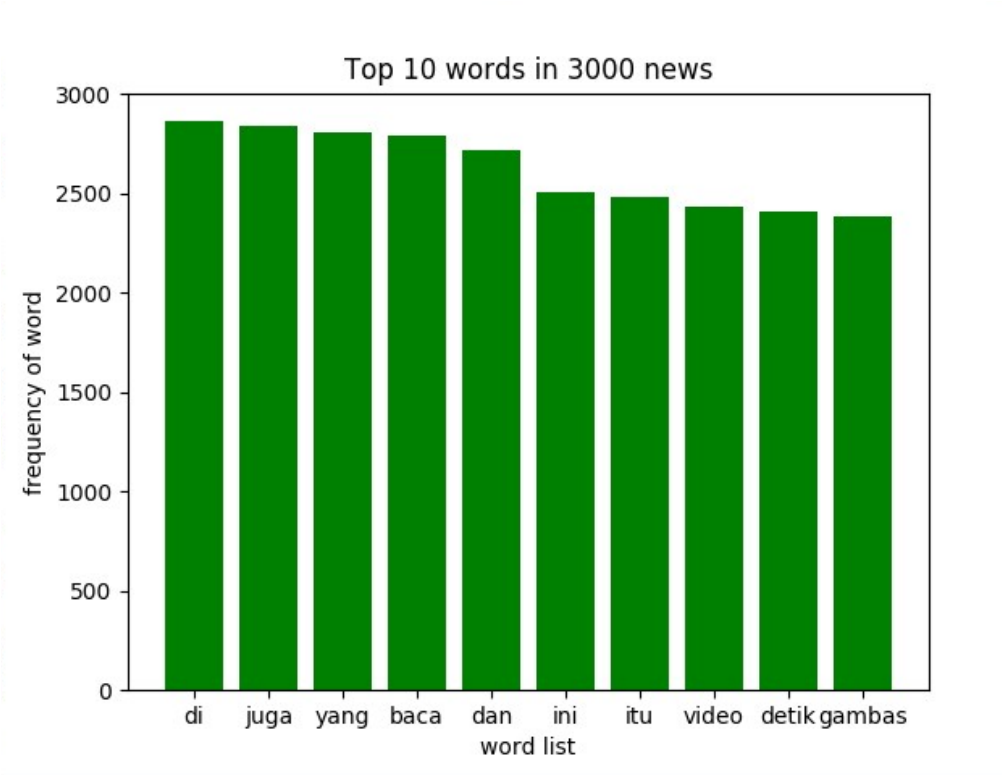

Gambar 7 : Bar Chart plotting

D. Line Chart Plotting

Tahapan ini hampir sama dengan tahapan bar char plotting, namun karena memiliki ketentuan untuk durasi 14 hari, maka kita akan melakukan pengecekan satu persatu file, apakah tanggal tersebut berkisar dari tanggal 01-07-2019 hingga 14-07-2019. Apabila tanggal sesuai, barulah dilakukan proses ngramming semua dan dimasukkan ke dalam hash untuk dicari top 10 kata terbanyak. Tidak lupa juga, frekuensi tiap kata perhari juga dimasukkan ke dalam hash, sehingga setelah didapatkan top 10 kata terbanyak, kita dapat memeriksa frekuensinya dari hari ke hari selama durasi 14 hari tersebut yang mana hash tersebut merupakan nested hash. Setelah itu, setiap data dimasukkan juga ke dalam array agar dapat dilakukan plotting data. Di sini saya menggunakan kode chart14days.py.

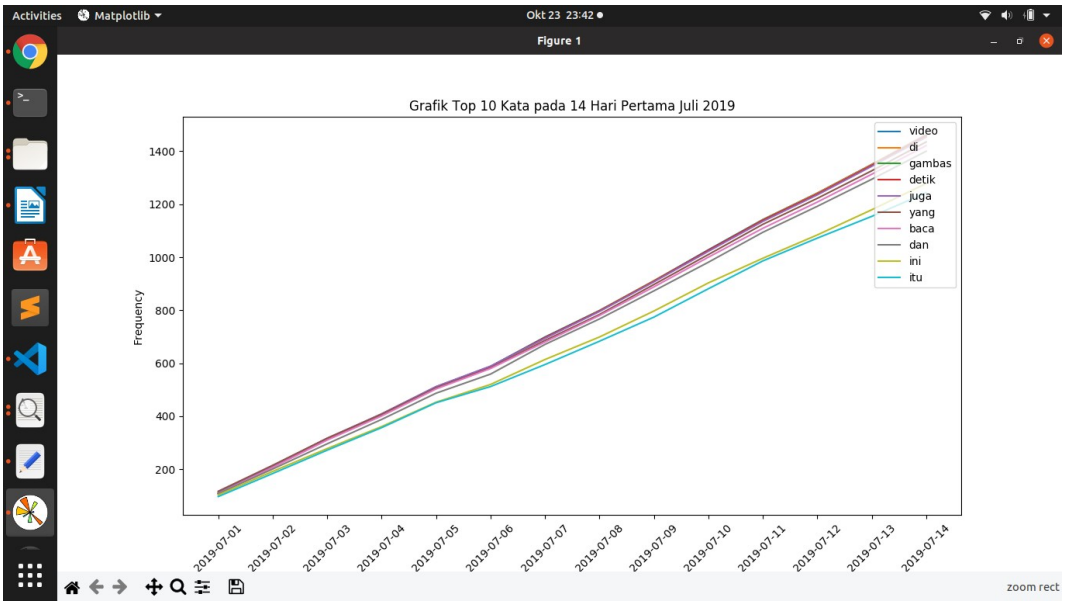

Gambar 8 : Line Chart Plotting

E. Pie Chart Plotting

Dengan menggunakan kode yang sama dengan bar chart sebelumnya, yaitu chart10best.py, namun pada saat melakukan ploting terdapat fungsi pie sehingga menghasilkan hasil berupa chart berbentuk pie. Di sini, tidak lupa value dalam hash sebelumnya dijadikan persentase dengan pembanding yaitu total 10 value tertinggi.

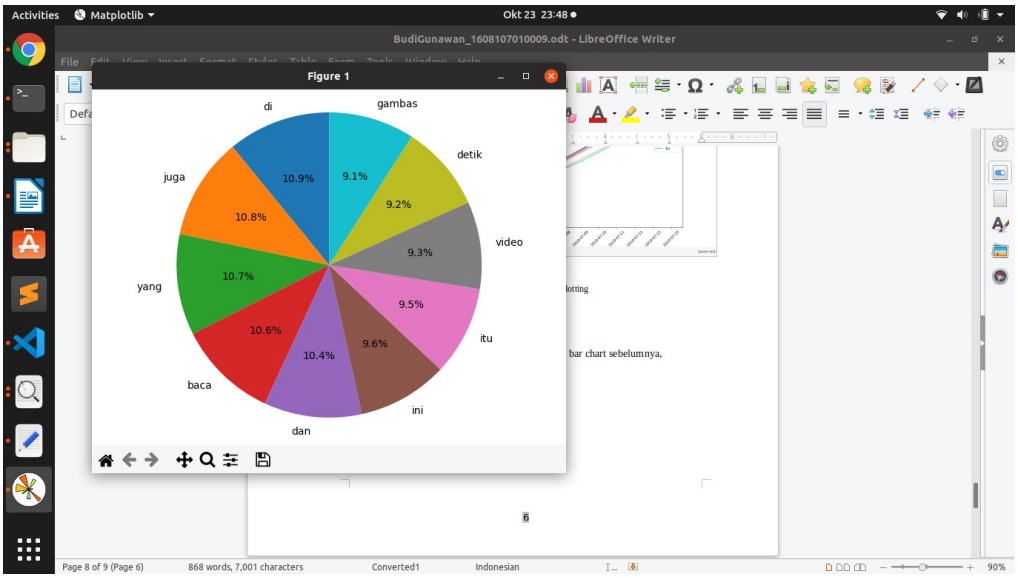

Gambar 9 : Pie Chart Plotting

KESIMPULAN

Adapun kesimpulan dari percobaan ini adalah :

1. Hasil data tertinggi terlalu berdekatan satu sama lain karena tidak menghilangkan stopword

SARAN

Adapun saran untuk perbaikan dalam project ini adalah agar terlebih dahulu menghilangkan stopword

LAMPIRAN

Berikut link berisi source code yang telah digunakan :

https://github.com/budigunawan99/PythonPlotting